

# O GRANDE TÍTULO

Alisson Rosa e Vítor Pereira

## Resumo

One Piece > Naruto

## Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
<b>2</b>	<b>Informações</b>	<b>1</b>
<b>3</b>	<b>Testes</b>	<b>5</b>
3.1	Tendência . . . . .	5
3.2	Sazonalidade . . . . .	5
3.3	Raiz unitária . . . . .	6
3.4	Resultados . . . . .	6
<b>4</b>	<b>Modelagem</b>	<b>6</b>
4.1	Dados de treino e teste . . . . .	6
4.2	Recipes . . . . .	7
4.3	Utilizando o Pacote Modeltime . . . . .	7
4.4	Utilizando outros Pacotes . . . . .	12
	<b>Referências</b>	<b>17</b>

## 1 Introdução

Naruto é uma animação japonesa (anime) que adapta a série de mangá escrita e ilustrada por Masashi Kishimoto, que conta a história de Naruto Uzumaki, um jovem ninja que constantemente procura por reconhecimento e sonha em se tornar Hokage, o ninja líder de sua vila.


A história é dividida em duas partes, a primeira parte se passa nos anos da pré-adolescência de Naruto (clássico), e a segunda parte se passa em sua adolescência (Shippuden). Nesse trabalho trataremos sobre o Naruto Shippuden, desenvolvendo-o em uma perspectiva de séries temporais, vamos adotar como variável de interesse a avaliação dos episódios, assim veremos pontos importantes da saga ao longo do tempo.

O Banco de dados utilizado é totalmente original, foi criado fazendo *Web scraping* de dois sites diferentes, para aqueles interessados o banco foi disponibilizado aqui.

## 2 Informações

Como o anime é uma adaptação, existem episódios fiéis ao mangá (Manga Canon) e episódios originais do próprio anime, em outras palavras não seguem o material original, esses episódios são chamados de Fillers, existem também episódios que seguem a trama do mangá mas além disso possuem elementos novos, esses chamados de Mixed Canon.

Vejamos pelo gráfico a seguir a porcentagem do tipo dos episódios




Fonte: Elaborado pelos autores

É um fato bastante curioso, Naruto Shippuden possui uma quantidade altíssima de episódios fillers, aproximadamente 41%, note pela tabela que são somente 31 episódios a mais canônicos.

Tabela 1: Valores Absolutos do Tipo de Episódio


Tipo	Quantidade
Filler	203
Manga Canon	234
Mixed Canon/Filler	63

Em termos de avaliação ao longo do tempo, podemos utilizar como índice ordinal o próprio número do episódio já que que é uma função injetora no tempo.




Há bastante coisa a se notar nesse gráfico, primeiramente pelos episódios 200 e 400, existe um indício de alteração na média das variáveis aleatórias, portanto furando o pressuposto de média constante ao longo do tempo, perto dos episódios finais da saga nota-se também inúmeras quedas bruscas na avaliação sem um contra-peso de avaliações com notas altas, outro indicio de não estacionariedade.

É importante tentarmos entender um pouco sobre esses episódios com notas baixas, assim vamos ver esse gráfico pelo tipo de episódio.



Assim fica fácil ver que os episódios com menor avaliação são em sua maior parte fillers, toda queda brusca de avaliação tem um episódio filler envolvido.

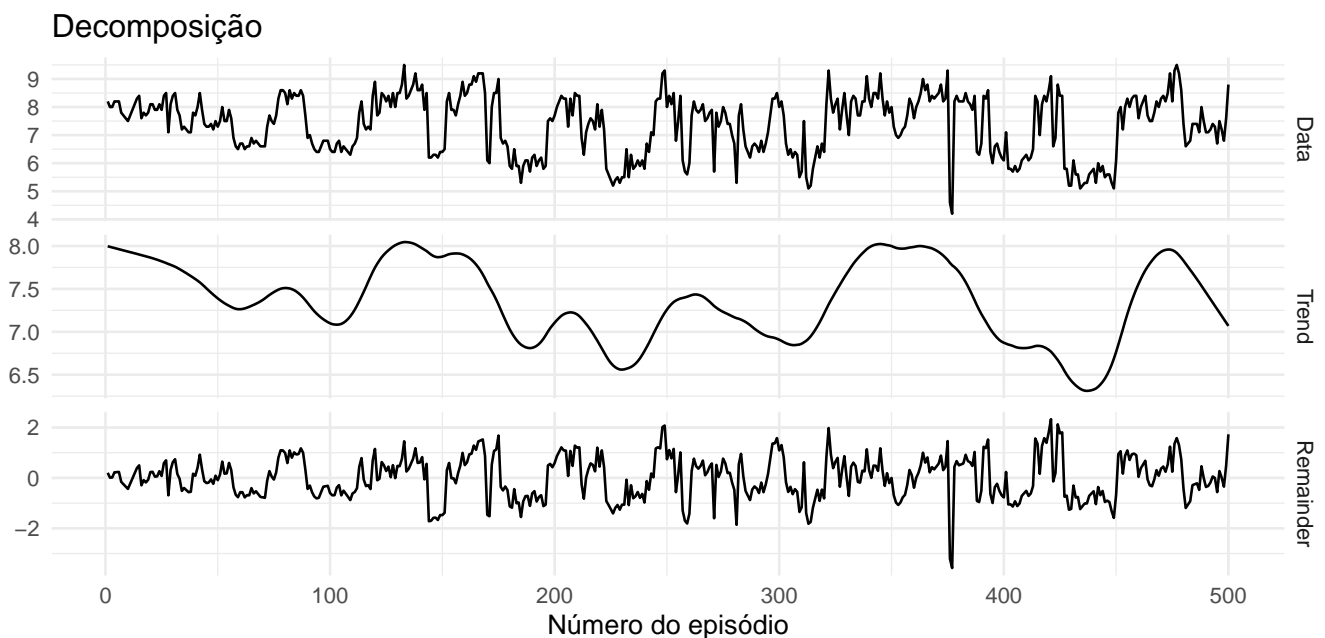
É necessário também avaliar a correlação nas avaliações:



Note que o gráfico anterior as autocorrelações tendem a ficar significativas até 10 defasagens, pois em média a duração dos arcos é 23.8, assim 10 defasagens significa em geral que:

- o episódio está tendo influência do final do arco anterior;
- o episódio está gozando consequências dos episódios iniciais do arco que está situado;
- o episódio está apanhando desfechos dos episódios pós metade do arco que está situado

Uma abordagem importante também é decompor a série temporal, apriori supõe-se a existência de três elementos, a saber: Tendência, sazonalidade e resíduo. Todos esses serão explorados cuidadosamente nas seções posteriores, assim vamos decompor a série para ter um vislumbre de tais elementos:



A questão de curiosidade vamos ver se os resíduos seguem uma distribuição normal, para isso utilizamos o teste de Shapiro Wilk que possui como hipótese:

$$H_0 : \text{Os dados seguem uma distribuição Normal}$$

Efetuada o teste obtemos um p-valor de 0.006, assim portanto rejeitando a hipótese  $H_0$ , porém os resíduos não possuírem distribuição normal não afetará as análises daqui pra frente.

### 3 Testes

Os gráficos de seção anterior evidenciaram a possibilidade da série não ser estacionária, assim faz-se necessário verificar se vale de fato para o processo estocástico, com isso vamos precisar aplicar testes de hipóteses para averiguar algumas propriedades, como existência de tendência e sazonalidade.

#### 3.1 Tendência

Tendência refere-se a um algum comportamento não - estocástico da série em algum momento do tempo, se tal comportamento só acontece em alguns momentos específicos do tempo, chamamos de tendência estocástica, do contrário é dita determinística. Vamos começar pelos testes de tendência determinística, que em termos sumarizados possuem como hipótese:

$$H_0 : \text{A série não possui tendência determinística}$$

Tabela 2: Testes de Tendência Determinística

Testes	P-valor
Cox-Stuart	0.050
Wald-Wolfowitz	0.000
Mann-Kendall	0.039

Conforme mostrado pela Tabela anterior podemos ver que pelos testes de Cox-Stuart, Wald-Wolfowitz, Mann-Kendall, temos que todos os p-valores são menores pequenos, então concluímos que existe tendência determinística na série temporal.

#### 3.2 Sazonalidade

Sazonalidade acontece quando a série possui um comportamento que se repete frequencialmente, vamos nessa subseção testar se existe sazonalidade nas avaliação dos episódios, assim temos como hipótese:

$$H_0 : \text{A série não possui sazonalidade}$$

Os testes aplicados foram Kruskal-Wallis, Friedman e Autocorrelação em lags Sazonais, assim gerando a seguinte tabela:

Tabela 3: Testes de Sazonalidade

Testes	P-valor
Kruskal-Wallis	0.745
Friedman	0.878
Autocorrelação em lags Sazonais	0.701

Assim, como os testes obtiveram p-valor > 0.5, concluímos portanto que não existem indícios de sazonalidade.

### 3.3 Raiz unitária

Para começar tal seção, primeiros vamos definir um passeio aleatório em sua forma simplificada:

$$Y_t = Y_{t-1} + \epsilon_t$$

Onde  $t$  refere-se aos índices de ordenação, e  $\epsilon$  um termo aleatório, para facilidade vamos assumir que  $E(\epsilon_t) = \mu$  e  $var(\epsilon_t) = \sigma^2 \forall t$ , assim subtraindo-se  $Y_{t-1}$  em ambos os lados tem-se

$$Y_t - Y_{t-1} = \epsilon_t$$

que é um processo estacionário, o processo anterior é dito processo estacionário em diferença, em outros casos também chamado de processo integrado. O exemplo anterior trata-se de um caso mais geral

$$Y_t = \phi Y_{t-1} + \epsilon_t$$

onde evidentemente  $\phi = 1$ , é fácil mostrar que se  $|\phi| < 1$  tem-se um processo estocástico, aqui portanto, estamos interessados nesse caso, para isso utilizaremos testes de hipótese.

Fala-se também que o caso anterior na forma simplificada possui raiz unitária, por causa do operador Lag, aqui não definido, porém pode-se ler sobre em [1]

Tabela 4: Testes de Tendência Estocástica

Testes	P-valor
Kwiatkowski-Phillips-Schmidt-Shin (KPSS)	0.1
Augmented Dickey-Fuller (ADF)	0.01*
Phillips-Perron (PP)	0.01*

Conforme mostrado pela Tabela anterior podemos ver que pelos testes de Dickey-Fuller Aumentado, Phillips-Perron, KPSS, com índice de significância de 5%, temos que os p-valores dos testes ADF e PP são menores que 0.05 e do teste KPSS é maior que 0.05, então concluímos que não existe tendência estocástica na série temporal. Pois, nos testes ADF e PP, a hipótese nula é a existência de raiz unitária e no teste de KPSS, a hipótese nula é não existência de raiz unitária.

### 3.4 Resultados

Vimos visualmente que a série a partir de um certo começa ter uma descrescimento, assim portanto dando um vislumbre de tendência determinística, aplicando os testes obtemos mais uma evidência de existência de tendência na série. Em relação a sazonalidade os testes também confirmaram o que os gráficos mostraram: não existe evidência de sazonalidade na série.


## 4 Modelagem

Nesta seção trabalharemos com os modelos para a série temporal, realizando a análise de métricas (MAE, MAPE, MASE, SMAPE, RMSE e RSQ), análise de resíduos e realizando previsões.

### 4.1 Dados de treino e teste

Utilizaremos para treinar os nossos modelos uma proporção de 80%, como temos uma amostra grande, os 20% são suficientes para os dados de teste, assim a série ficará da seguinte maneira:

## Avaliação de Naruto Shippuden Dados de Treino e Teste



## 4.2 Recipes

Utilizaremos 6 recipes (receitas): normal, mês e ano como covariáveis, dia do ano como covariável, trimestre e semestre, utilizando lags e utilizando séries de Fourier.

## 4.3 Utilizando o Pacote Modeltime

Aqui iremos testar diversos modelos como: suavização exponencial (ets), suavização exponencial no modelo de espaço de estado SSOE, suavização exponencial theta (equivalente a suavização exponencial simples com tendência constante (drift) e o procedimento Prophet do Facebook, é um modelo aditivo utilizando tendências não lineares, para entender mais o modelo Prophet [clique aqui](#).

### 4.3.1 Suavização exponencial

Começaremos utilizando todos os modelos ets possíveis, smooth\_es, theta e croston. Assim, para escolhermos os melhores. Sendo ao total 51 modelos testados.

**4.3.1.1 Ajustando os modelos** Para os modelos de suavização exponencial iremos os escolher pelo menos um modelo que seja o melhor em cada uma dessas categorias: Erro Aditivo, Erro Multiplicativo, Sem Tendência, Tendência Aditiva, Tendência Multiplicativa, Tendência Amortecida, Sem Sazonalidade, Sazonalidade Aditiva, Sazonalidade Multiplicativa e bom  $R^2$ .

Já no ajuste de modelos podemos perceber que a suavização exponencial não pode utilizar de algumas combinações de erro, tendência e sazonalidade, esses são modelos são: ets(A,N,M), ets(A,A,M), ets(A,AD,M), ets(A,M,N), ets(A,MD,N), ets(A,M,A), ets(A,MD,A), ets(A,M,M), ets(A,MD,M), ets(M,M,A) e ets(M,MD,A). Assim, temos que entre os modelos válidos, escolhendo a melhor combinação de receita e modelos, temos as seguintes métricas para cada modelo: (ordenados pela métrica MAE)

Tabela 5: Métricas dos Modelos de Suavização Exponencia

rank	.model_desc	mae	mape	mase	smape	rmse	rsq
1	ETSX(MAN)	0.9482563	13.76290	2.063239	13.52065	1.107536	0.1541240
3	ETS(MAN)	0.9503808	13.83595	2.067861	13.53914	1.107940	0.1541242
4	ETS(M,A,N)	0.9506912	13.84659	2.068537	13.54501	1.107840	0.1541242
10	ETS(MAA)	0.9588516	13.84171	2.086293	13.66376	1.123567	0.1329984
11	ETSX(MAA)	0.9598439	13.87724	2.088452	13.67609	1.123165	0.1331725
13	CROSTON METHOD	1.0566146	15.54127	2.299008	15.09949	1.204980	NA
19	ETSX(MMM)	1.0910167	14.79220	2.373861	15.57832	1.300304	0.0827720
21	ETS(MMM)	1.1242293	15.11030	2.446125	16.07203	1.344843	0.0703107
22	ETS(M,M,M)	1.1572583	15.51976	2.517991	16.57406	1.377681	0.0310785
28	ETSX(ANM)	1.1764872	16.02217	2.559829	16.87385	1.364653	0.0076139
29	ETSX(MNN)	1.2462616	16.49726	2.711646	17.94631	1.480544	0.1541241
31	ETS(M,N,N)	1.2529108	16.54194	2.726114	18.05000	1.493865	NA
37	ETS(MNN)	1.2529333	16.54211	2.726163	18.05036	1.493907	NA
39	ETS(M,MD,N)	1.2538124	16.55009	2.728075	18.06417	1.495339	0.0849640
45	ETS(M,AD,N)	1.2566748	16.58070	2.734303	18.10941	1.499276	0.1351984
51	ETSX(ANA)	1.2572438	16.66570	2.735541	18.12533	1.493752	0.0080862
52	ETSX(ANN)	1.2597240	16.59663	2.740938	18.15692	1.506055	0.1541242
53	ETS(M,N,A)	1.2616011	16.66740	2.745022	18.19174	1.503203	0.0047931
59	ETS(M,MD,M)	1.2622415	16.68977	2.746415	18.20149	1.501747	0.0119256
65	ETS(ANM)	1.2647154	16.70804	2.751798	18.24044	1.507543	0.0092757
66	ETS(ANA)	1.2664086	16.73464	2.755482	18.26878	1.509865	0.0090474
68	ETS(M,AD,M)	1.2692679	16.74742	2.761704	18.31245	1.513117	0.0100718
74	ETS(M,A,M)	1.2695095	16.76412	2.762229	18.31714	1.513554	0.0140288
80	ETS(A,AD,A)	1.2720614	16.77874	2.767782	18.35787	1.519923	0.0101815
87	ETS(A,N,N)	1.2764738	16.74424	2.777383	18.42147	1.534184	NA
93	ETS(ANN)	1.2766417	16.74570	2.777748	18.42413	1.534473	NA
94	ETS(A,AD,N)	1.2767148	16.74648	2.777907	18.42529	1.534574	0.0624370
100	ETS(A,N,A)	1.2785790	16.84264	2.781963	18.46063	1.530631	0.0125995
106	ETS(M,N,M)	1.2830405	16.90115	2.791671	18.53364	1.535727	0.0112603
112	THETA METHOD	1.2846034	16.83626	2.795071	18.55142	1.544815	0.1541242
118	ETS(M,A,A)	1.2913573	17.00737	2.809766	18.66618	1.541874	0.0222350
124	ETS(M,AD,A)	1.3483684	17.57995	2.933813	19.58484	1.626831	0.0582191
130	ETS(A,A,N)	1.4355075	18.59210	3.123412	21.03802	1.742123	0.1541242
136	ETSX(AAN)	1.4418638	18.66746	3.137242	21.14579	1.750517	0.1541242
137	ETS(AAN)	1.4423830	18.67268	3.138372	21.15451	1.751335	0.1541242
138	ETS(A,A,A)	1.4551112	18.85483	3.166066	21.37075	1.766832	0.1171396
145	ETS(AMA)	1.7832282	22.88661	3.879991	27.25304	2.187881	0.1628969
146	ETSX(AMA)	1.8083857	23.20880	3.934729	27.73209	2.219819	0.1624729

Assim os modelos escolhidos foram: - ETSX(M,A,N) - melhor modelo - ETS(M,A,N) - melhor modelo da suavização exponencial normal - Croston - Bom método num geral e é de engine diferente - Theta - Bom  $R^2$  e é de engine diferente - ETSX(M,A,A) - Melhor modelo com sazonalidade aditiva - ETSX(M,M,M) - Melhor modelo com sazonalidade multiplicativa - ETSX(A,N,M) - Melhor modelo com erro aditivo e sem tendencia - ETS(M,M,M) - Segundo melhor modelo da suavização exponencial normal - ETS(M, MD, N) - Melhor modelo com tendencia amortecida - ETSX(M,N,N) - Modelo equilibrado em todas as medidas e com bom  $R^2$  entre os ETS() - ETSX(A,M,A) - Modelo com melhor  $R^2$

#### 4.3.2 Modelos Prophet

Para a seleção dos modelos prophet realizamos o procedimento de tunnar hiperparâmetros considerando duas características, sazonalidade, poderia aditiva ou multiplicativa, crescimento, poderia linear ou logístico, assim como utilizamos



duas engines para tunnar os hiperparâmetros: XGBoost e Catboost.

Assim utilizaremos 4 modelos Prophets para o ajuste de modelos e comparação com os modelos de suavização exponencial: - Prophet com todos hiperparâmetros padrões e engine xgboost; - Prophet com crescimento logístico, changepoint\_range 0.8, restante de hiperparâmetros padrões e engine xgboost; - Prophet com crescimento logístico, changepoint\_range 0.8628, changepoint\_num 33, trees 2000, tree\_depth 2, learn\_rate 0.000975, mtry 7 e engine xgboost; - Prophet com crescimento linear, changepoint\_range 0.7323, changepoint\_num 29, trees 2000, tree\_depth 4, learn\_rate 0.00335856, mtry 9 e engine catboost;

### 4.3.3 Ajustando os modelos

Com os modelos ajustados, agora podemos ver quais são os 20 modelos possuem as melhores métricas, ordenados de acordo com o rmse:

Tabela 6: Métricas nos dados de teste

.model_id	rank	.model_desc	.type	mae	mape	mase
extrafeatures_lag_M_prophet_boost_logM	1	PROPHET XGBOOST TUNNADO	Test	0.657	9.54	1.43
extrafeatures_lag_M_prophet_boost_log	2	PROPHET XGBOOST	Test	0.701	9.55	1.53
extrafeatures_lag_M_prophet_boost	3	PROPHET XGBOOST DEFAULT	Test	0.764	11.07	1.66
features_M_smooth_etsMAN	4	ETSX(MAN)	Test	0.948	13.76	2.06
base_M_etsMANN	5	ETS(M,A,N)	Test	0.951	13.85	2.07
extrafeatures_fourier_M_etsMANN	6	ETS(M,A,N)	Test	0.951	13.85	2.07
extrafeatures_lag_M_etsMANN	7	ETS(M,A,N)	Test	0.951	13.85	2.07
extrafeatures_M_etsMANN	8	ETS(M,A,N)	Test	0.951	13.85	2.07
features_day_M_etsMANN	9	ETS(M,A,N)	Test	0.951	13.85	2.07
features_M_etsMANN	10	ETS(M,A,N)	Test	0.951	13.85	2.07
features_day_M_smooth_etsMAN	11	ETSX(MAN)	Test	0.950	13.83	2.07
base_M_smooth_etsMAN	12	ETS(MAN)	Test	0.950	13.84	2.07
features_day_M_smooth_etsMAA	13	ETSX(MAA)	Test	0.960	13.88	2.09
base_M_smooth_etsMAA	14	ETS(MAA)	Test	0.959	13.84	2.09
features_M_prophet_boost	15	PROPHET XGBOOST DEFAULT	Test	0.987	13.83	2.15
extrafeatures_M_prophet_boost	16	PROPHET XGBOOST DEFAULT	Test	0.995	13.97	2.16
features_M_smooth_etsMAA	17	ETSX(MAA)	Test	0.997	14.89	2.17
base_M_prophet_boost_log	18	PROPHET XGBOOST	Test	1.002	15.42	2.18
extrafeatures_fourier_M_prophet_boost_logM	19	PROPHET XGBOOST TUNNADO	Test	1.058	15.62	2.30
extrafeatures_M_prophet_boost_logM	20	PROPHET XGBOOST TUNNADO	Test	1.057	15.63	2.30

Assim temos também que as métricas no dados de treino são:


Tabela 7: Métricas nos dados de treino

Modelo	MAE	MAPE	MASE	SMAPE	RMSE	RSQ
PROPHET XGBOOST TUNNADO	0.500	7.16	1.147	6.91	0.650	0.624
PROPHET XGBOOST	0.193	2.64	0.442	2.62	0.270	0.932
PROPHET XGBOOST DEFAULT	0.203	2.79	0.465	2.77	0.277	0.929
ETSX(MAN)	0.457	6.48	1.048	6.29	0.674	0.570
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETS(M,A,N)	0.467	6.62	1.071	6.42	0.688	0.552
ETSX(MAN)	0.464	6.58	1.065	6.38	0.685	0.556
ETS(MAN)	0.464	6.58	1.065	6.38	0.686	0.555
ETSX(MAA)	0.463	6.55	1.063	6.37	0.678	0.564
ETS(MAA)	0.463	6.55	1.063	6.36	0.679	0.563
PROPHET XGBOOST DEFAULT	0.426	6.02	0.978	5.89	0.577	0.698
PROPHET XGBOOST DEFAULT	0.388	5.49	0.891	5.37	0.541	0.720
ETSX(MAA)	0.457	6.47	1.048	6.28	0.668	0.579
PROPHET XGBOOST	0.829	11.79	1.902	11.39	0.981	0.045
PROPHET XGBOOST TUNNADO	0.790	11.36	1.814	10.88	0.941	0.245
PROPHET XGBOOST TUNNADO	0.797	11.45	1.829	10.96	0.949	0.185


**4.3.3.1 Gráficos** Nesta seção será mostrado alguns gráficos interessantes dos seguintes modelos: Prophet's, ETSX(MAN), ETS(MAN) do smooth, ETS(MAN) do forecast e ETS(MAA) do smooth.

#### 4.3.3.1.1 Prophet

Prophet com Catboost




Prophet com XGboost tunnado



Legend — ACTUAL — 1\_PROPHET W/ XGBOOST ERROR

Prophet com XGboost




Prophet com XGboost default




Legend — ACTUAL — 1\_ETSX(MAN)

#### 4.3.3.1.2 Suavização Exponencial




Legend — ACTUAL — 1\_ET S(M,A,N)



Legend — ACTUAL — 1\_ET S(M,A,N)



Legend — ACTUAL — 1\_ET SX(MAA)



Legend — ACTUAL — 1\_PROPHET W/ XGBOOST ERRO

#### 4.3.4 Reajuste do modelo

Agora iremos reajustar o modelo utilizando não apenas os dados de treino, mas toda a base de dados.

Para começar a análise dos modelos reajustados temos, as seguintes métricas para os dados completos:

Tabela 8: Métricas na série inteira

Modelo	MAE	MAPE	MASE	SMAPE	RMSE	RSQ
CROSTON METHOD	0.718	10.27	1.625	9.97	0.911	0.262
ET S(M,A,N)	0.463	6.57	1.049	6.39	0.685	0.600
ET S(M,M,M)	0.470	6.66	1.064	6.48	0.682	0.603
PROPHET XGBOOST DEFAULT	0.848	12.18	1.921	11.78	1.010	0.085
PROPHET XGBOOST	0.858	12.34	1.942	11.91	1.019	0.069
PROPHET XGBOOST TUNNADO	0.907	13.04	2.054	12.56	1.059	0.014
ET S(AMA)	0.452	6.34	1.022	6.24	0.670	0.623
ET S(ANM)	0.451	6.34	1.020	6.23	0.670	0.623
ET S(MAA)	0.462	6.54	1.046	6.36	0.677	0.612
ET S(MAN)	0.464	6.58	1.049	6.40	0.685	0.599
ET S(MMM)	0.467	6.60	1.057	6.44	0.679	0.607
ET S(MNN)	0.466	6.57	1.054	6.43	0.685	0.598
THETA METHOD	0.450	6.32	1.018	6.21	0.679	0.614
CROSTON METHOD	0.718	10.27	1.625	9.97	0.911	0.262
ET S(M,A,N)	0.463	6.57	1.049	6.39	0.685	0.600
ET S(M,M,M)	0.470	6.66	1.064	6.48	0.682	0.603
PROPHET XGBOOST DEFAULT	0.288	4.07	0.653	4.02	0.380	0.896
PROPHET XGBOOST	0.276	3.89	0.625	3.85	0.367	0.902
PROPHET XGBOOST TUNNADO	0.828	12.03	1.876	11.51	0.978	0.307
THETA METHOD	0.450	6.32	1.018	6.21	0.679	0.614


#### 4.3.5 Análise de resíduo

## # A tibble: 14 x 6



##	.model_id	.model_desc	shapiro_wilk	box_pierce	ljung_box	durbin_watson
##	<int>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
## 1	1	ETS(AMA)	4.22e-16	0.235	0.234	1.88
## 2	1	ETS(ANM)	4.43e-16	0.206	0.205	1.88
## 3	1	THETA METHOD	5.38e-17	0.222	0.221	1.88
## 4	1	THETA METHOD	5.38e-17	0.222	0.221	1.88
## 5	1	PROPHET XGBOOST DE~	2.86e- 9	0.836	0.836	1.98
## 6	1	PROPHET XGBOOST	1.92e- 8	0.985	0.985	1.99
## 7	1	THETA METHOD	5.38e-17	0.222	0.221	1.88
## 8	1	THETA METHOD	5.38e-17	0.222	0.221	1.88
## 9	1	ETSX(AMA)	5.17e-16	0.226	0.225	1.88
## 10	1	ETSX(ANM)	5.58e-16	0.202	0.201	1.88
## 11	1	THETA METHOD	5.38e-17	0.222	0.221	1.88
## 12	1	ETSX(AMA)	2.83e-14	0.162	0.161	1.86
## 13	1	ETSX(ANM)	2.36e-14	0.190	0.189	1.88
## 14	1	THETA METHOD	5.38e-17	0.222	0.221	1.88

Então apenas 7 dos nossos modelos passaram nos testes de Shapiro-Wilk, Box-Pierce e Ljung-Box: ETS(A,M,A), ETS(A,N,M), THETA, PROPHET XGBOOST DEFAULT, PROPHET XGBOOST, ETSX(A,M,A) e ETSX(A,N,M). Desses nossos 7 modelos apenas 2 apresentaram boas métricas: PROPHET XGBOOST DEFAULT e PROPHET XGBOOST. Então esses seriam os modelos indicados para a predição e previsão da Série Temporal.

#### 4.3.5.1 Gráficos



Legend — ACTUAL — 1\_PROPHET W/ XGBOOST ERROR



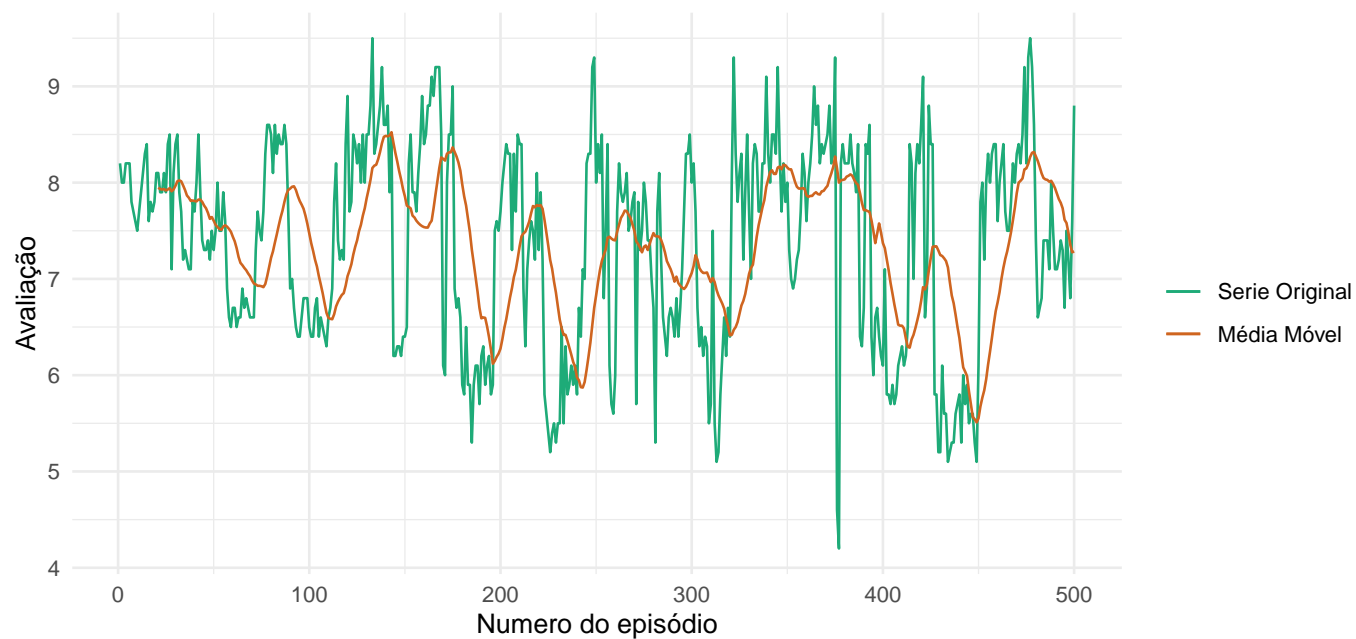
Legend — ACTUAL — 1\_ETSX(MAN)

Legend — ACTUAL — 1\_PROPHET W/ XGBOOST ERROR


## 4.4 Utilizando outros Pacotes


Nesta seção iremos construir a modelagem de séries temporais utilizando outros pacotes além do modeltime, como o pacote forecast, smooth e SMA principalmente para construção de modelos holt, médias móveis e regressão LOESS.

#### 4.4.1 Médias Móveis Simples




##### 4.4.1.1 Previsão Utilizando o pacote smooth, temos a seguinte previsão





#### 4.4.2 Regressão LOESS



```
## Holt-Winters exponential smoothing with trend and multiplicative seasonal component.
##
## Call:
## HoltWinters(x = treino, seasonal = "multiplicative")
##
## Smoothing parameters:
##  alpha: 0.747
##  beta : 0
##  gamma: 0.515
```


```

##
## Coefficients:
##      [,1]
## a      6.23957
## b     -0.00792
## s1     0.97274
## s2     0.94760
## s3     0.97191
## s4     0.97599
## s5     1.04107
## s6     1.06997
## s7     1.06873
## s8     1.03901
## s9     1.04321
## s10    1.00204
## s11    1.01854
## s12    1.01820
## s13    0.98331
## s14    0.98048
## s15    1.04988
## s16    1.03390
## s17    1.05076
## s18    1.05857
## s19    1.06820
## s20    1.04287
## s21    0.99206
## s22    0.95780
## s23    0.92976
## s24    0.92432
## s25    0.93824
## s26    0.92864
## s27    0.87862
## s28    0.79702
## s29    0.86606
## s30    0.93552
## s31    0.88901
## s32    0.92278
## s33    0.91405
## s34    0.89616
## s35    0.90375
## s36    0.93849
## s37    0.95931
## s38    1.03572
## s39    1.03496
## s40    1.00495
## s41    1.05577
## s42    1.15630
## s43    1.17270
## s44    1.05047
## s45    1.03678
## s46    1.01539
## s47    1.05935
## s48    1.07748
## s49    1.06448
## s50    1.00373


```

```
## s51 0.98643
## s52 0.97885
```

#### 4.4.3 Holt não Amortecido



#### 4.4.4 Holt com Amortecimento





#### 4.4.5 Calculando Métricas de Acurácia dos Modelos não-ModelTime

Tabela 9: Métricas nos dados de teste

	MAE	MAPE	MASE	SMAPE	RMSE	RSQ
SMA	1.08	15.9	2.36	15.5	1.23	0.060
Holt	1.44	18.6	3.12	21.0	1.74	0.154
Holt amortecido	1.28	16.7	2.78	18.4	1.53	0.062

## [1] 23.8

## Referências

- [1] Morettin PA, Toloi CM. Análise de séries temporais: Modelos lineares univariados. Editora Blucher; 2018.